

الأسبوع الأول

Introduction

التعليم المشرف :Supervised

- التقسيم Classification
- نظام الـ Linear Regression
- التوقع Regression

● التعليم غير المشرف : Unsupervised

- المجموعات Clustering
- نظام الـ K Mean

● مجالات تعلم الآلة :

- الطب
- الطائرات
- مواقع مثل الفيس و امازون
- الايميلات

● تعريفه :

- هو جعل الآلة تتعلم بنفسها دون توجيه بشري
- هو جعل الآلة تتعلم عبر مشاهدتها خبرة سابقة للانسان (E) للمهمة المطلوبة (T) ثم نقيم ادائها لاحقا (P)
- فلو عايزين الايميل يفلتر الايميلات السبام او توماتيك ، فكون انه يشوفك بتعمل سبام للايميلات E
- انه هو يقوم بعمل مهمة الفلتره بنفسه T
- اننا نقيس مهارته في فلتره الايميلات و عدم اللغطة P
- نوعيه:
- المشرف وغير المشرف

○ أهمية الخوارزميات

- النجار اللي راح اتعلم ان ده شاكوش و ده منشار ، وشكرا ، هو نفسه اللي راح اتعلم ادوات تعلم الآلة من غير ما يفهم الخوارزميات ، لان الخوارزميات هي نفسها طريقة استخدام ادوات تعلم الآلة ، و من غيرها مفيش انجاز

● التعليم باشراف Supervised ML

- لعمل مثال بسيط عليه . عندك اسعار بيوت و مساحاتها ، و عندك بيانات ، فممكن تعمل جراف بينهم ، و تعمل خط مستقيم او دالة تربيعية لتوقع البيت الفلاني سعره كام (المثال ده ريجريشين)
- لو فيه مقارنة بيه حجم الورم و هل هو خبيث ولا حميد ، فبرضه تعمل جراف و نتوقع (كلاسيكاشن)

● التعليم غير المشرف

- كمية ضخمة من البيانات و يتم تقسيمها الي مجموعات , كل مجموعة بسلوك محدد , ولها امثلة كثيرة , مثلما يقوم جوجل بتقسيم الاخبار كل علي حدة بشكل تلقائي , ومن امثلتها
 - تقسيم منتجات امازون
 - اقتراح الاصدقاء في الفيسبوك
 - تقسيم المركب لسيجمنتات
 - تقسيم اصوات متداخل (اتنين بيتكلمو في نفس الوقت) لصوتين منفصلين
 - والغريب ان هذا الامر يتم بسطر واحد في البرنامج

● الادوات المستخدمة

- ماتلاب
- اوكتيف :
- الاستخدام الامثل ان تتعلم اوكتيف اولاً , ثم تركبه علي سي بلس بلس او جافا

● الاستنتاج الخطي Linear Regression

- و يسمى أيضا (One Varilable Regression) او (Unvariate Regression)
- يستخدم مع الامثلة البسيطة نوعا , و مع عامل واحد
- يتم استخدام معادلة خطية من الدرجة الاولى :


Linear regression equation (without error)

$$\hat{Y} = bX + a$$

predicted values of Y

b = slope = rate of predicted \uparrow/\downarrow for Y scores for each unit increase in X

Y-intercept = level of Y when X is 0



- و هنا المعادلة الخاصة بيها
- الهدف تقليل الفارق بين قيمة $h(x)$ و هي القيمة المتوقعة من المعادلة الخطية و قيمة y و هي القيمة الحقيقية بمعادلة تشابه الانحراف المعياري
- ويتم القسمة علي $2m$ لربط قيمة الخطا بعدد القيم بالعينة
- الهدف ايجاد قيم ثيتا 1 و ثيتا 2 , والتي تجعل من J (نسبة الخطا) اقل ما يمكن
- تسمى احيانا Cost error function


Hypothesis: $h_{\theta}(x) = \theta_0 + \theta_1 x$

Parameters: θ_0, θ_1

Cost Function: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

Goal: $\underset{\theta_0, \theta_1}{\text{minimize}} J(\theta_0, \theta_1)$


- نري علي اليسار قيم ثيتا 1 (معامل اكس و بفرض ان ثيتا صفر الحد المطلق يساوي صفر) مع hx وكلما زادت قيمة ثيتا 1 زاد السلوب , بينما نري علي اليمين قيمة الخطا الناشئ من زيادة او تقليل قيمة ثيتا , فنجد ان القيمة المثلي الان هي 1 (تختلف بالطبع في قيم اخري)



$$J(0) = \frac{1}{2m} (1^2 + 2^2 + 3^2) = \frac{1}{6} \cdot 14 \approx 2.3$$

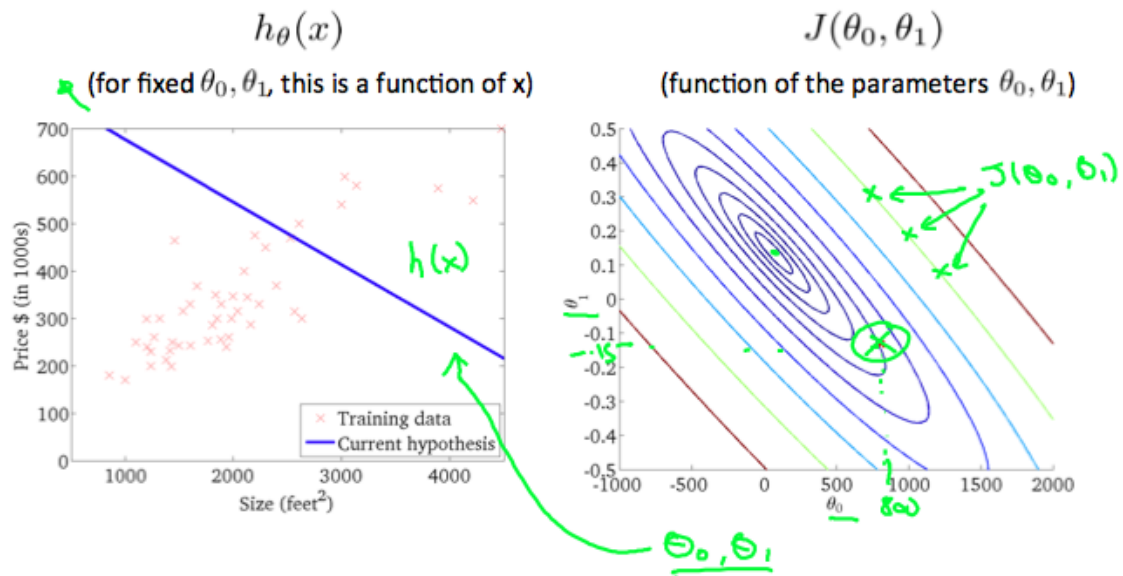
$h(x) = -0.5x$

minimize $J(\theta_1)$

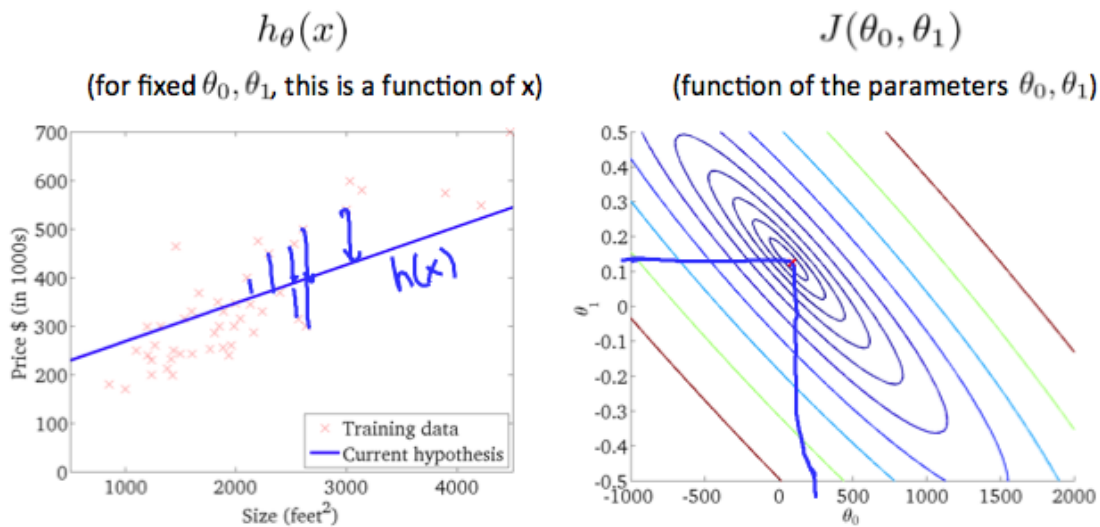



Andrew Ng

- المثال السابق كان مع تصفير ثيتا صفر و التلاعب فقط بثيتا 1 , الان اذا لعبنا بكلا من ثيتا 1 و ثيتا 0 , فسيكون لدينا عاملين , وبالتالي يجب ان تكون معادلة J مع الثيتتين , يجب ان تكون كونتور لنتمكن من قرائتها
- مع معلومية ان كل خط و كيرف من اليمين , يمثل قيمة ثابتة لـ J حتي لو اختلفت الثيتتين
- فمثلا الدائرة الحمراء البعيدة خالص , تمثل قيمة كبيرة لـ J (مثلا 20) و اي نقطة تقع عليها بقيم ثيتا 1 و ثيتا 2 هتجيب قيمة J بـ 20 والدائرة الاصغر شوية 19 , وهكذا
- من المنطقي اننا لو عايزين اقل قيمة لـ J (الـ J هي قيمة الفروق بين القيم الحقيقية و المتوقعة) يبقى نروح للدائرة الاصغر وهي الصفر او قيمة قريبة للصفر
- نأخذ النقطة الحمراء كمثال , وهي تمثل ثيتا 0 تساوي 800 و ثيتا 1 تساوي سالب 1.5 , وبالتالي نرسمها مخط مستقيم علي اليمين بالمعادلة : $h(x) = 800 - 1.5x$



- ونفس الموضوع لو اخذنا كذا نقطة من اليمين و اللي تمثلها خط علي الشمال , لغاية لما نلاقي ان افضل حل هو النقطة اللي في نص الاشكال البيضاوية علي اليمين , اللي تمثل بالظبط افضل بيت فيت لايين






● الطريقة المستخدمة عموما في تعليم الالة كالتالي :

- بيانات للتدريب
- الالة تتعرف علي الموديل
- يتم تكوين النظرية او المعادلة في الالة
- الان اذا اعطيناها اكس (المعطي) , تعطينا واي (المطلوب)


● فكرة الـ Gradient Descent

- طالما نحن نبحث عن قيم ثيتا 1 و 2 التي ستقلل قيمة J باقصي قدر , فسنفرض قيم لثيتا 1 و 2 , ثم نقوم بتقليلها تدريجيا حتي نصل لاقل قيمة للـ J
- لكن حاذر اننا قد نقل لقيم مختلفة قليلة للـ J حسب من اين سنبدأ



- فهناك ما يسمى local minimum يعني قيمة دنيا , لكن محلية (علي اليمين) و لا نري جوارها اي قيم دنيا اخري , لكن في الحقيقة هناك قيم اقل منها لكن ابعد

○ والقيمة الأقل جميعا اسمها global minimum وهي المطلوبة , مثل هذا الشكل



○ و معادلة الوصول لافضل قيمة هي :

repeat until convergence:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

- اولاً فكرة ان $=$ معناها ان يا برنامج , اعمل **overwrite** للقيمة اليسرى بقيمة اليميني
- الفا هو معامل , ان زاد , ستكون الخطوات اسرع (و غالباً اقل دقة) و ان قل ستكون الخطوات ابطئ و ادق
- ما هو علي يمين الفا , هو اشتقاق جزئي للدالة , بالنسبة لثيتا
- لاحظ ان هذه المعادلة تكون مرة لثيتا صفر , ومرة لثيتا 1
- كلا المعادلتين يمشيان بالتوازي معا , ويتم تكرارهما معا
- ولاحظ ان الابديت لازم يتم زي اللي علي الشمال , مش اليمين

Correct: Simultaneous update

```

→ temp0 := θ₀ - α ∂/∂θ₀ J(θ₀, θ₁)
→ temp1 := θ₁ - α ∂/∂θ₁ J(θ₀, θ₁)
→ θ₀ := temp0
→ θ₁ := temp1

```

Incorrect:

```

→ temp0 := θ₀ - α ∂/∂θ₀ J(θ₀, θ₁)
→ θ₀ := temp0
→ temp1 := θ₁ - α ∂/∂θ₁ J(θ₀, θ₁)
→ θ₁ := temp1

```

- لان اللي علي الشمال , بتدخل قيم ثيتا 0 و 1 الحالية مع بعض , بينما علي اليمين الغلط , بتدخل في المعادلة الثانية قيمة ثيتا 0 المعدلة , وده هيلغبط الدنيا
- لاحظ ان في حالة القيمة الدنيا قيمة التفاضل بصفر (لأن وقتها هيكون الخط شبه مستقيم فالميل هيكون تقريبا 0)

- لاحظ ان قيمة التفاضل تقل كلما قل الميل (التفاضل هو ميل الخط المستقيم , فتدريجيا هيقل قيمة التفاضل لتغير الميل) , وكلما اقترب من القيمة الدنيا , فلا داعي لتقليل الالف , فالقيمة نفسها ستقل تدريجيا
- نقوم بالتفاضل , نجد انها ستكون :

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m ((h_{\theta}(x_i) - y_i)x_i)$$

- رقم 2 راح لانه اتضرب في الاس , ولاحظ اننا بنفاضل بالنسبة لثيتا 0 في الاول و ثيتا 1 في الثانية فبقت كدة

● الـ Vectors

- مش المقصود بيها المتجهات , لكن يقصد بها انها عمود في مصفوفة , او كانها مصفوفة , ذات عمود واحد , وبمقدار مختلف من الصفوف
- و حينما يشار الي y2 مثلا , فيقصد بها القيمة الثانية (الصف الثاني) في الفيكتور

● الـ Matrix

- يستخدم ضرب الماتركس في شئ مهم هنا , لو عندي مساحات 4 بيوت علي اليسار , وعندي 3 معادلات للتقييم علي اليمين , فممكن اعمل لهم تقييم كامل سريع عبر تكوين ماتركس عمودها الاول وحيد (لأنها ستضرب في ثيتا 0) , عمودها الثاني مساحات البيوت , والماتركس الثاني عدد عواميدها هي عدد معادلات التقييم , بها صفين , فيها قيمة ثيتا 0 و ثيتا 1 , لكل معادلة
- ستجد ان ضرب الماتركسين في بعضهما , ستكون ماتركس جديدة , قيمة العمود الأول فيها هو اسعار البيت الاول للتقييمات الثلاث , وهكذا

House sizes:

$$\begin{bmatrix} 2104 \\ 1416 \\ 1534 \\ 852 \end{bmatrix}$$

Have 3 competing hypotheses:

$$1. h_{\theta}(x) = -40 + 0.25x$$

$$2. h_{\theta}(x) = 200 + 0.1x$$

$$3. h_{\theta}(x) = -150 + 0.4x$$

Matrix

$$\begin{bmatrix} 1 & 2104 \\ 1 & 1416 \\ 1 & 1534 \\ 1 & 852 \end{bmatrix}$$

Matrix

$$\begin{bmatrix} -40 \\ 0.25 \end{bmatrix} \begin{bmatrix} 200 \\ 0.1 \end{bmatrix} \begin{bmatrix} -150 \\ 0.4 \end{bmatrix}$$

$$\begin{bmatrix} 486 & 410 & 692 \\ 314 & 342 & 416 \\ 344 & 353 & 464 \\ 173 & 285 & 191 \end{bmatrix}$$

Prediction
of first
 h_{θ}

Predictions
of 2nd
 h_{θ}

Andrew Ng

- فمن المهارات المطلوبة لمبرمج الـ ML ان يكون لديه القدرة علي صياغة مصفوفة و تشكيلها بطرق عديدة , حتي يتمكن من استخدام ضربها و جمعها الترانزيوس , ليصل للنتيجة المطلوبة