

الأسبوع الثاني

Linear Regression with Multiple Variables

● التعامل مع أكثر من بعد :

- تحدثنا سابقا , عن التعامل مع متغير واحد (قيمة لأكس و نجيب منها قيمة واي) الان نتعامل مع أكثر من متغير
- أكثر من متغير معناها ان البيانات الداخلة لها أكثر معلومة لكل صف , فبدلا من ادخال مساحة البيت لمعرفة سعره (أكس واحدة) , نقوم بادخال مساحة البيت و عدد غرفه , وعمره , و موقعه , وحالته , ولونه , لتحديد سعره , وهذه الأشياء تسمى features

Multiple features (variables).

Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
x_1	x_2	x_3	x_4	y
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...

$m = 47$

Notation:

- n = number of features $n = 4$
- $x^{(i)}$ = input (features) of i^{th} training example.
- $x_j^{(i)}$ = value of feature j in i^{th} training example.

- فنري ان سعر البيت (Label Y) يتاثر بعدد من العوامل (Features Xs)
- عدد الاكسات نسميه n , بينما عدد الصفوف لازال m
- عشان منتلغبطش , هنعمل التسمية ديه

$$x_j^{(i)} = \text{value of feature } j \text{ in the } i^{th} \text{ training example}$$

- الرقم اللي فوق يكون رقم الصف (انهي ريكورد فيهم m) و الرقم اللي تحت هيكون رقم العمود (انهي معلومة فيهم n)
- وقتها الفنكشن , هتكون متعددة الحدود زي كدة , وهنعمل ماتركس للاكسات , وواحدة للثيتات , ونضربهم في بعض بعد ما نعمل ترانزبوس لوحدة فيهم
- ليه بنعمل ترانزبوس ؟ لان الثيتا و الاكس اصلا هما فيكتورات (عمود واحد في كذا صف) , فلازم اعمل ترانزبوس لواحد فيهم و اضربه في الثاني , عشان تكون المصفوفة الاولى صف واحد في 5 عواميد مثلا , والثانية زي ما هي 5 صفوف في عمود واحد , يتضربو بيقو رقم واحد بس

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

For convenience of notation, define $x_0 = 1$. ($x_0^{(i)} = 1$)

$$x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1} \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \in \mathbb{R}^{n+1}$$

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

$$= \begin{bmatrix} \theta_0 & \theta_1 & \dots & \theta_n \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

(n+1) x 1 matrix

Multivariate linear regression. ←

- وخذ بالك الصيغة القديمة اللي كانت لـ J هيكون فيها شوية تعديل , عشان مبقاش عامل واحد , نفس المعادلة , لكن دلوقتي H بقت فيها ثبات كتيرة
- لما اعمل تفاضل , هتظل انتش زي هي , وهيموت كل الثبات التانية عدا الثبات اللي باعمل تفاضل علي اساسها اللي هتتبعني في الاخر

```
repeat until convergence: {
  theta_0 := theta_0 - alpha * 1/m * sum_{i=1}^m (h_theta(x^(i)) - y^(i)) * x_0^(i)
  theta_1 := theta_1 - alpha * 1/m * sum_{i=1}^m (h_theta(x^(i)) - y^(i)) * x_1^(i)
  theta_2 := theta_2 - alpha * 1/m * sum_{i=1}^m (h_theta(x^(i)) - y^(i)) * x_2^(i)
  ...
}
```

- عشان كدة ممكن اعمل صيغة عامة زي ديه

```
repeat until convergence: {
  theta_j := theta_j - alpha * 1/m * sum_{i=1}^m (h_theta(x^(i)) - y^(i)) * x_j^(i)   for j := 0...n
}
```

- لاحظ ان ثباتا 0 مكانش فيها اكس صفر , بس مفيش مشاكل من وضعه لان اساسا اكس صفر = 1

● إعادة التكمير Rescaling


- لو كانت قيم اكس 1 و اكس اثنين بتدرجات مختلفة , يعني الاول ينتهي عند 5 و الثاني 2000 مثلا , هنلاقي الكونتورز لرسم الـ J طويلة و رفيعة او العكس , وده هيخلي عملية الـ gradient descent طويلة جدا
- فالحل اننا نخلي سكيل جميع الاكسات علي 1 بس , فنقسم اي قيمة لأكس 1 علي القيمة الاقصى لأكس واحد

Feature Scaling

Idea: Make sure features are on a similar scale.

E.g. $x_1 = \text{size (0-2000 feet}^2)$ ←


$x_2 = \text{number of bedrooms (1-5)}$ ←



$$\rightarrow x_1 = \frac{\text{size (feet}^2)}{2000}$$

$$\rightarrow x_2 = \frac{\text{number of bedrooms}}{5}$$

$$0 \leq x_1 \leq 1 \quad 0 \leq x_2 \leq 1$$



- كدة هيتحول الرسم لعادي , وهتكون قيم اكس كلها بين 0 وواحد والعملية هتكون اسرع
- كمان لمزيد من الدقة و السرعة فيما بعد , ممكن نطرح كل قيم اكس , ناقص المتوسط (هيتم اعطاؤه او نجيبه احنا) علي الرينج (الرقم الاكبر ناقص الرقم الاصغر)

Mean normalization

Replace x_i with $x_i - \mu_i$ to make features have approximately zero mean
(Do not apply to $x_0 = 1$).

E.g. $x_1 = \frac{\text{size} - 1000}{2000}$

$$x_2 = \frac{\# \text{bedrooms} - 2}{5}$$

Average size = 1000

1-5 bedrooms

$$-0.5 \leq x_1 \leq 0.5, -0.5 \leq x_2 \leq 0.5$$

$$x_i \leftarrow \frac{x_i - \mu_i}{s_i}$$

← avg value of x_i in training set
← range (max-min)

- وده هيخلي غالبا ارقام اكسات كلها بتلعب من 1 لسالب 1, وبشكل عام , مفيش مشكلة لو كان الرقم بين 3 و سالب 3

● احاول كام مرة ؟ ؟

- من الواضح ان كل ما بنحاول اكثر , قيمة J بتقل و ديه حاجة كويسة , بس ياتري هنحاول كام مرة ؟ ؟
- الرسمة هنا واضح فيها ان كل ما بنزود عدد المحاولات , كل ما قيمة J هتقل اكثر , بس بعد فترة معينة السلوب بيقترب لصفر , و بيكون فيه عدد ضخم جدا من المحاولات مع فرق بسيط , و هنا لازم نوقف , عشان هيكون ضياع وقت علي الفاضي
- ممكن نوقف بعد 5 او 50 او 5 مليون محاولة , محدش هيقدر يحدد الرقم كام , كل حالة بحالتها

$\min_{\theta} J(\theta)$

$J(\theta)$ should decrease after every iteration

$J(\theta)$

0 100 200 300 400

No. of iterations

30, 3000, 3,000,000

→ Declare convergence if $J(\theta)$ decreases by less than 10^{-3} in one iteration.

● تحديد قيمة الفا

-
- Figure 1.3 illustrates three different convergence behaviors of an optimization process, plotted against the number of iterations (x-axis):
- A:** The function $T(\theta)$ (y-axis) decreases rapidly and approaches zero, indicating fast convergence.
 - B:** The function $J(\theta)$ (y-axis) decreases and approaches a constant value, indicating convergence to a minimum.
 - C:** The function $J(\theta)$ (y-axis) increases and approaches a constant value, indicating convergence to a maximum.


- $\dots, \underline{0.001}, \underline{0.003}, \underline{0.01}, \underline{0.03}, \underline{0.1}, \underline{0.3}, \underline{1}, \dots$
 $\uparrow \quad \quad \quad \nearrow \times \quad \quad \nearrow \approx \times \quad \quad \nearrow \times \quad \quad \nearrow \approx \times \quad \quad \uparrow \quad \quad \uparrow$

- هات 0.001 و جرب , لو الخطوات صغيرة , اضرب في 3 , يعني 0.003 , لسة صغيرة , اضرب في 3 يعني 0.01 و هكذا , اول ما الاقي القيمة كبرت ارجع خطوة ورا


● التعديل في عدد البيانات

- لو عندنا بيت ، وسعره يقيم علي اساس طوله و عرضه , فممکن نعمل حاجتين
 - بدل ما يكون الاعتماد علي عنصرين X_1, X_2 , فهتكون معادلة فيها 3 ثيتا و تغلبنا , نجيب المساحة مكانها باعتبارها تشمل الطول و العرض , وتكون معادلة خطية X_1 بس
 - اننا نجيب المساحة و تكون بيان اضافي للطول و العرض فيكون فيه X_1, X_2, X_3

● اختيار نوع الدالة



- لاحظ ان النقط الحمراء و هي البيانات , لو همتلها بمعادلة خطية (بناء علي المتغير X) فممكن متدينش الخط المناسب
- فممكن افكر في معادلة تربيعية (بناء علي X , X تربيع) , بس المعادلة التربيعية بتؤول انها تنزل تحت و ده غلط عمليا (سعر البيت مش هيقبل بزيادة المساحة) فالافضل اخليها معادلة تكعيبية اللي بتطلع لفوق (اس , اكس تربيع , اكس تكعيب) و ده صح منطقيا
- الكلام اللي فات ده كان علي دالة سعر البيت , بس وارد المعادلة التربيعية تكون مناسبة مثلا لعدد العمال اللي هجيبهم المصنع و المكسب (لو زاد عدد العمل عن المطلوب هيعمل خسائر و ده منطقي)
- ممكن استعين بالمعادلة الجذرية (روت اكس جنب الاكس) , وديه بتخلي الرسم (flattered) قدام , وده وارد يكون مناسب لنوع معين من المشاكل



● طريقة الـ Normal Equation

- و هي عن طريق الاعتماد علي تفاضل الـ J و مساوتها بالصفر لايجاد قيمة الثيتا المطلوبة

Examples: $m = 4$.

	Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
x_0	x_1	x_2	x_3	x_4	y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178

$X = \begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \end{bmatrix}$ $m \times (n+1)$

$y = \begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \end{bmatrix}$ m -dimensional vector

○ و اذا كان لدينا جدول مثل هذا لاكثر من متغير , فبعد مفاضلتها و مساوتها بالصفر ستكون الثيتا كالتالي

$$\theta = (X^T X)^{-1} X^T y$$

- و متنساش ان دايمًا ماتركس اكسات فيها اول عمود وحيد بس (عشان يتضرب في ثيتا صفر و يعمل نفس قيمتها) بعدها قيم اكسات , بينما ماتركس واي هي فيكتور لقيم واي تحت بعض
- أيهما أفضل : الجرادينت ولا النورمال اكواشن :

- النورمال ميزتها ان مش محتاج تحسب قيمة الفا , و مش هتعمل خطوات كثير , هي خطوة واحدة
- بس عيبها انها بتكون صعبة و بطيئة جدا مع عدد كبير للخواص n لان الماتركس هتكون مخيفة خاصة لعمل الانفرس , فلو عدد الـ N يقول عن 10 الاف خليك في النورمال , زادت روح للجراديننت
- كمان فيه خوارزميات (زي linear regression) مش هينفع تشتغل الا بالجراديننت , و خوارزميات تانية ممكن بالنورمال , فلازم تكون عارف الاتنين و تشوف مين مناسب لايه

- أحيانا بتحصل مشكلة في نوع النورمال , ان ماتركس اكس ترانسبوز في اكس تكون singular و معناها ان مش هينفع يتعمل لها انفرس , وده هيلغبط الدنيا
- غالبا بيكون سبب انها انفرس حاجة من اتنين
 - اما يكون فيه عمودين معتمدين علي بعض , يعني فيه مثلا مساحة البيت بالمتر المربع , ومساحة البيت بالقدم المربع , وده معناه ان فيه عمود كامل يساوي عمود ثاني مضروب في فاكتر , وده هيودي ان قيمة الماتركس كلها تساوي صفر , فالانفرس هيختفي
 - ان عدد الـ m (عدد الصفوف) اقل من عدد الـ n (العوامل او المعلومات عن كل بيت) خاصة لو الفرق كبير , فا اما تمسح شوية عوامل مش مهمة , او تزود بيانات و صفوف , او تشوف نوع ثاني

التعلم علي كود برنامج Octave من الملف الخاص به

- مثال عملي : هنجيب دالة الكوست باستخدام اوكتيف

$$\text{Cost Function: } J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- دالة الكوست عبارة عن : واحد علي ضعف عدد السامبل , مضروبة في مجموع مربعات فروق قيمة الاتش من قيمة الواي
- قيمة الاتش عبارة حاصل ضرب الاكسات في الثيتا
- الأول هنكتب الكود في ملف خارجي بامتداد m وهو :

function J = costfunctionJ(x,y,theta)

m = size(x,1);

predictions = x*theta;

sgrrors = (predictions -y).^2;

J = (1/(2*m))* sum(sgrrors);

- اول سطر تعريف للفنكشن , والمدخلات و المخرج
- ثاني حاجة باعرف الفنكشن , ان الام هي عدد صفوف الماتركس اكس اللي هدخلها
- بعدها باعمل ماتركس جديدة اسمها بريدكشنز (اللي هي كانها قيم H), وهي حاصل ضرب ماتركس اكس في ماتركس ثيتا
- لاحظ ان قيم اكس , انا اضفت عليها عمود علي الشمال (قيمة X0) اللي هو وحيد , عشان لما يتضرب في ثيتا 0 يكون نفس القيمة , ولما قيم اكس تتضرب في ثيتا واحد يدونا الرقم المطلوب
- ضرب المصفوفتين هيعملنا مصفوفة جديدة اللي هي البريديكشن
- دلوقتي نطرح مصفوفة البريديكشن من مصفوفة الواي عشان اجيب الفرق
- بعدها اعمل سكوير لقيمهم بس (مش ماتركس سكوير) عشان كدة عملت بوينت قبل ما اعمل سكوير , عشان اقوله عايز سكوير لقيمهم
- اخر حاجة اني اضرب 1 علي ضعف الـ m , مضروبة في مجموع كل قيم الماتركس الاخيرة

● دلوقتي ندخل البيانات

- >> x = [1 1;1 2;1 3] مصفوفة اكس مضاف اليها وحيد علي الشمال و هتبقى كدة

```
1  1
1  2
1  3
```

- >> y = [1;2;3] قيم واي , و هتبقى كدة

```
1
2
```

- احنا عارفين القيم , بس بفرض اننا مش عارفينها , وديه القيم اللي ممكن قدام نغيرها عشان `>> theta = [0;1]` نجيب افضل قيم ليها
- اكتب الفنكشن داخل فيها التلات حاجات دول , يجيلي جي `>> j = costfunctionJ(x,y,theta)`
 - ولو غيرنا اي قيمة في اكسات او وايات او ثباتات هتلاقي الناتج مختلف

تتبع الاختبار الاول

- هي مجموعة من الملفات المرتبطة ببعض , ويقودها الملف الرئيسي ex1 والذي يذهب الي باقي الملفات و الفنكشنز

Ex1()	
<pre>%% Machine Learning Online Class - Exercise 1: Linear Regression % Instructions % ----- % This file contains code that helps you get started on the % linear exercise. You will need to complete the following % functions % in this exercise: % % warmUpExercise.m % plotData.m % gradientDescent.m % computeCost.m % gradientDescentMulti.m % computeCostMulti.m % featureNormalize.m % normalEqn.m % For this exercise, you will not need to change any code % in this file, % or any other files other than those mentioned above. % % x refers to the population size in 10,000s % y refers to the profit in \$10,000s % %% Initialization</pre>	كل هذه مقدمة يشرح فيها المطلوب
<code>clear ; close all; clc</code>	لتصفير البيانات كلها
<pre>%% ===== Part 1: Basic Function =====</pre>	لطباعة كلمة كذا و كذا

<pre>% Complete warmUpExercise.m fprintf('Running warmUpExercise ... \n'); fprintf('5x5 Identity Matrix: \n'); warmUpExercise()</pre>	للذهاب للفنكشن وارم اب
warmUpExercise()	
<pre>function A = warmUpExercise() A = eye(5); end</pre>	اسم الدالة , وتكوين دالة ادينيتي 5 في 5
Ex1()	
<pre>fprintf('Program paused. Press enter to continue.\n'); pause;</pre>	كتابة الجملة , ثم التوقف
<pre>fprintf('Plotting Data ... \n')</pre>	كتابة الجملة
<pre>data = load('ex1data1.txt');</pre>	تحميل الملف اللي فيه الداتا
<pre>X = data(:, 1); y = data(:, 2);</pre>	الاكس فيكتور يساوي جميع الارقام اليسري , والواي تساوي الارقام اليميني
<pre>m = length(y); % number of training examples</pre>	الام رقم يساوي عدد صفوف الواي او الاكس
<pre>plotData(X, y);</pre>	نذهب لفنكشن الرسم
PlotData()	
<pre>function plotData(X, y)</pre>	اسم الدالة و متغيراتها
<pre>plot (X, y, 'rx', 'MarkerSize', 10);</pre>	لرسم الدالة , ورقم 10 يعتبر حجم النقطة , و ار اكس و الماركر متغيرات لتحديد الرسم
<pre>ylabel('Profit in \$10,000s'); xlabel('Population of City in 10,000s');</pre>	كتابة العناوين علي محوري اكس وواي
<pre>figure; % open a new figure window</pre>	لاظهار الرسم
Ex1()	
<pre>X = [ones(m, 1), data(:,1)]; % Add a column of ones to x</pre>	لاضافة عمود بعدد ام علي يسار الاكس بحيث يكون مصفوفة ام في 2 مش في 1
<pre>theta = zeros(2, 1); % initialize fitting parameters</pre>	عمل ثيتا مصفوفة اصفار 2 في 1
<pre>iterations = 1500; alpha = 0.01;</pre>	عدد المحاولات , وقيمة الفا

<code>fprintf("\nTesting the cost function ...\n')</code>	اظهار كلام
<code>J = computeCost(X, y, theta);</code>	حساب الجي بالدالة ديه
ComputeCost()	
<code>function J = computeCost(X, y, theta)</code>	تعريف الدالة
<code>m = length(y); J = 0;</code>	تحديد قيمة ام , وقيمة اولية للجى
<p>Hypothesis: $h_{\theta}(x) = \theta_0 + \theta_1 x$</p> <p>Parameters: θ_0, θ_1</p> <p>Cost Function: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$</p> <p>Goal: $\underset{\theta_0, \theta_1}{\text{minimize}} J(\theta_0, \theta_1)$</p>	هنا المعادلة المطلوبة
<code>f = (X * theta);</code>	هنعمل مصفوفة لضرب قيم اكس في ثيتا
<code>g = f-y;</code>	هنعمل مصفوفة تانية لطرق قيمة المصفوفة اللي عملناها من واي
<code>h = g.^2;</code>	مصفوفة جديدة لتكوين مربعات قيم المصفوفة اللي فانت
<code>o = sum(h);</code>	هنجمع قيم المصفوفة علي بعض
<code>J = o / (2*m)</code>	اخيرا , هنقسم قيمة المجموع علي 2 في ام
Ex1()	
<code>fprintf('With theta = [0 ; 0]\nCost computed = %f\n', J); fprintf('Expected cost value (approx) 32.07\n');</code>	رغي
<code>J = computeCost(X, y, [-1 ; 2]);</code>	حساب الجى مرة اخري بنفس الدالة
<code>fprintf('\nWith theta = [-1 ; 2]\nCost computed = %f\n', J); fprintf('Expected cost value (approx) 54.24\n'); fprintf('Program paused. Press enter to continue.\n'); Pause; fprintf('\nRunning Gradient Descent ...\n')</code>	رغي
<code>theta = gradientDescent(X, y, theta, alpha, iterations);</code>	تعريف الفنكشن الي هنروحها
gradientDescent()	

function [theta, J_history] = gradientDescent(X, y, theta, alpha, num_iters)	اسم الدالة , وهبطع منها معلومتين , مصفوفة ثيتا النهائية (2 في 1) , وجي هيبستوري , وديه ماتريكس عمود واحد فيها كل قيم جي اللي طلعت
m = length(y); J_history = zeros(num_iters, 1);	تحديد ام , و تكوين جي هيبستوري , بحيث يكون عدد صفوفها هو عدد المحاولات اللي تم تحديده من شوية 1500
for iter = 1:num_iters	نبدأ الفور , ولعدد 1500 مرة
$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)$ $\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m ((h_{\theta}(x_i) - y_i)x_i)$	هنا الدالة اللي هنمشي عليها , الثيتا هي الثيتا الاصلية , د الف علي ام , مضروبة في مجموع قيم اتش ناقص واي و ثيتا واحد زيتها بس المجموع مضروب في اكس 1 الاول
th1 = theta(1,1); th2 = theta(2,1);	تحديد متغيرين ياخذو قيم ثيتا من المصفوفة
f = (X * theta);	مصفوفة جديدة ضرب اكس في ثيتا (1*97)
g1 = f-y; o1 = sum(g1); l1 = (alpha * o1) / m;	طرحها من واي (1*97) مجموعها (رقم) اضرب في الفا علي إم
s2 = X(:,2); g2 = (f-y).*s2; o2 = sum(g2); l2 = (alpha * o2) / m;	مصفوفة تشيل قيم اكس علي اليمين من غير وحيد (1*97) اطرح و اضرب القيم فيها اجيب مجموعها و اقسمة علي ام في الفا
th1 = th1 - l1; th2 = th2 - l2; theta = [th1 ; th2];	اطرح كل ده من الثيتات , واعمل ابديت لمصفوفة الثيتا
J_history(iter) = computeCost(X, y, theta); end	احسب قيمة ثيتا بالمعادلة القديمة , واحطها في جي هيبستوري , واقل الفور
Ex1()	
fprintf('Theta found by gradient descent:\n'); fprintf('%f\n', theta); fprintf('Expected theta values (approx)\n'); fprintf(' -3.6303\n 1.1664\n\n');	عرض قيمة الثيتا
hold on; % keep previous plot visible	سبب الرسمة القديمة متقلهاش

<pre>plot(X(:,2), X*theta, '-') legend('Training data', 'Linear regression') hold off % don't overlay any more plots on this figure</pre>	<p>لرسم الخط البيست فبت لتحديد القيم المكتوبة خلاص اقلل الرسمة</p>
<pre>predict1 = [1, 3.5] *theta; fprintf('For population = 35,000, we predict a profit of %f\n',... predict1*10000); predict2 = [1, 7] * theta; fprintf('For population = 70,000, we predict a profit of %f\n',... predict2*10000);</pre>	<p>هنطبق الثيتا , عن طريق ضرب رقم 1 , و 3.5 في الثيتتين , و نشوف قيمة الواي كام , ونطبق كمان مر , ونعرض النتائج</p>
<pre>fprintf('Program paused. Press enter to continue.\n'); pause; fprintf('Visualizing J(theta_0, theta_1) ...\n')</pre>	<p>رغي و التحضير لعرض الرسم المصور لثيتا</p>
<pre>theta0_vals = linspace(-10, 10, 100); theta1_vals = linspace(-1, 4, 100);</pre>	<p>هنعمل قيم كثيرة للثيتا 0 و ثيتا 1 , عن طريق فنكشن بتعمل فيكتور , وهي عدد 100 رقم (الرقم الايمن) يبدأ من سالب 10 (الايسر) و ينتهي عند 10 (الوسط) و زيتها اللي تحت</p>
<pre>J_vals = zeros(length(theta0_vals), length(theta1_vals));</pre>	<p>هنعمل مصفوفة اصفار , هيكون بعديها طولي الرقمين اللي فوق , يعني 100*100</p>
<pre>for i = 1:length(theta0_vals) for j = 1:length(theta1_vals) t = [theta0_vals(i); theta1_vals(j)]; J_vals(i,j) = computeCost(X, y, t); end end</pre>	<p>هنملي المصفوفة الكبيرة 100*100 , بقيمة كوست كل مرة , بحيث كل قيمة نعوض فيها بمقدار ثيتا صفر , و ثيتا 1 و الاكس و الواي الثابتين , ونملي بيها المصفوفة الكبيرة</p>
<pre>J_vals = J_vals';</pre>	<p>هنعمل ترانزبوس للمصفوفة الكبيرة , لان الرسم مش هيعرف يتعامل معاها كدة</p>
<pre>figure; surf(theta0_vals, theta1_vals, J_vals) xlabel('\theta_0'); ylabel('\theta_1');</pre>	<p>الدالو سريف بترسم ثلاثي الابعاد , وهنحط قيم ثيتتين , ومع مكتبة الجي</p>
<pre>contour(theta0_vals, theta1_vals, J_vals, logspace(-2, 3, 20)) xlabel('\theta_0'); ylabel('\theta_1'); hold on;</pre>	<p>لرسم الدوائر البيضاوية</p>
<pre>plot(theta(1), theta(2), 'rx', 'MarkerSize', 10, 'LineWidth', 2);</pre>	<p>لتحديد موضع الثيتا النموذجية</p>